

Customer Shopping Behavior Analysis

Resumo do Projeto

Introdução

Este notebook foi desenvolvido com o objetivo de analisar o comportamento de compra dos clientes, identificando padrões de consumo, avaliações, preferências de produtos e métricas relevantes para análise de dados.

O projeto utiliza **Python**, **Pandas** e **PostgreSQL** para realizar consultas, tratamento de dados e geração de insights, permitindo uma análise mais eficiente e estruturada das informações.

Processo de Limpeza e Tratamento de Dados

Antes de iniciar as análises, foi necessário realizar um processo de limpeza e preparação dos dados. Essa etapa é fundamental, pois dados brutos normalmente apresentam inconsistências, valores ausentes, duplicidades e formatos inadequados, fatores que podem comprometer a qualidade das análises e dos resultados obtidos.

Principais etapas realizadas

1. Padronização de colunas

Os nomes das colunas foram organizados e padronizados para facilitar consultas, manipulações futuras e melhorar a legibilidade do dataset.

2. Tratamento de valores nulos

Foram identificados campos vazios ou incompletos, evitando erros em cálculos estatísticos, agregações e análises posteriores.

3. Conversão de tipos de dados

Algumas colunas tiveram seus tipos ajustados, garantindo compatibilidade entre dados numéricos, textos e informações utilizadas nas análises.

4. Remoção de inconsistências

Foi realizada a correção de possíveis valores inválidos ou registros fora do padrão esperado, melhorando a confiabilidade das informações.

5. Preparação para SQL e visualização

Os dados foram estruturados para permitir consultas mais eficientes no PostgreSQL e facilitar futuras análises em ferramentas de visualização, como o Power BI.

Importância da limpeza de dados

A limpeza de dados é uma das etapas mais importantes em qualquer projeto de análise de dados, pois decisões tomadas com informações incorretas podem gerar insights equivocados.

Além disso, um dataset limpo proporciona:

- Melhor performance nas consultas;
- Maior organização dos dados;
- Mais precisão nas análises;
- Facilidade na criação de dashboards e relatórios;
- Maior confiabilidade nos resultados finais.

2. Resumo do Dataset

- **Linhas:** 3.900
- **Colunas:** 18

Principais Características:

- **Dados demográficos dos clientes** (*Age, Gender, Location, Subscription Status*)
 - **Detalhes das compras** (*tem Purchased, Category, Purchase Amount, Season, Size, Color*)
 - **Comportamento de compra** (*Discount Applied, Promo Code Used, Previous Purchases, Frequency of Purchases, Review Rating, Shipping Type*)
 - **Dados Ausentes:** 37 valores faltantes na coluna Review Rating.
-

3. Análise Exploratória de Dados utilizando Python

Iniciamos o projeto com a preparação e limpeza dos dados utilizando Python.

Etapas realizadas:

- **Carregamento dos Dados:**
O dataset foi importado utilizando a biblioteca `pandas`.
- **Exploração Inicial:** Foi utilizado `df.info()` para verificar a estrutura dos dados e `df.describe()` para gerar estatísticas descritivas e resumidas do dataset.

<code>df.describe(include='all')</code>																		
	Customer ID	Age	Gender	Item Purchased	Category	Purchase Amount (USD)	Location	Size	Color	Season	Review Rating	Subscription Status	Shipping Type	Discount Applied	Promo Code Used	Previous Purchases	Payment Method	Frequency of Purchases
count	3900.000000	3900.000000	3900	3900	3900	3900.000000	3900	3900	3900	3900	3863.000000	3900	3900	3900	3900	3900.000000	3900	3900
unique	NaN	NaN	2	25	4	NaN	50	4	25	4	NaN	2	6	2	2	NaN	6	7
top	NaN	NaN	Male	Blouse	Clothing	NaN	Montana	M	Olive	Spring	NaN	No	Free Shipping	No	No	NaN	PayPal	Every 3 Months
freq	NaN	NaN	2652	171	1737	NaN	96	1755	177	999	NaN	2847	675	2223	2223	NaN	677	584
mean	1950.500000	44.068462	NaN	NaN	NaN	59.764359	NaN	NaN	NaN	NaN	3.750065	NaN	NaN	NaN	NaN	25.351538	NaN	NaN
std	1125.977353	15.207589	NaN	NaN	NaN	23.685392	NaN	NaN	NaN	NaN	0.716983	NaN	NaN	NaN	NaN	14.447125	NaN	NaN
min	1.000000	18.000000	NaN	NaN	NaN	20.000000	NaN	NaN	NaN	NaN	2.500000	NaN	NaN	NaN	NaN	1.000000	NaN	NaN
25%	975.750000	31.000000	NaN	NaN	NaN	39.000000	NaN	NaN	NaN	NaN	3.100000	NaN	NaN	NaN	NaN	13.000000	NaN	NaN
50%	1950.500000	44.000000	NaN	NaN	NaN	60.000000	NaN	NaN	NaN	NaN	3.800000	NaN	NaN	NaN	NaN	25.000000	NaN	NaN
75%	2925.250000	57.000000	NaN	NaN	NaN	81.000000	NaN	NaN	NaN	NaN	4.400000	NaN	NaN	NaN	NaN	38.000000	NaN	NaN
max	3900.000000	70.000000	NaN	NaN	NaN	100.000000	NaN	NaN	NaN	NaN	5.000000	NaN	NaN	NaN	NaN	50.000000	NaN	NaN

- **Tratamento de Dados Ausentes:**
Foram verificados valores nulos e os valores ausentes da coluna `Review Rating` foram preenchidos utilizando a mediana das avaliações de cada categoria de produto.
- **Padronização de Colunas:**
As colunas foram renomeadas para o formato *snake_case*, melhorando a legibilidade, padronização e documentação do projeto.
- **Engenharia de Features:**
 - Foi criada a coluna `age_group`, agrupando os clientes por faixa etária.
 - Foi criada a coluna `purchase_frequency_days`, baseada nos dados de frequência de compras.
- **Verificação de Consistência dos Dados:**
Foi analisado se as colunas `discount_applied` e `promo_code_used` continham informações redundantes. Após a verificação, a coluna `promo_code_used` foi removida.
- **Integração com Banco de Dados:**
O script em Python foi conectado ao PostgreSQL e o DataFrame tratado foi carregado no banco de dados para realização das análises em SQL.

4. Análise de Dados utilizando SQL (Transações de Negócio)

Foi realizada uma análise estruturada no PostgreSQL para responder perguntas importantes relacionadas ao negócio.

1. Receita por Gênero

Comparação da receita total gerada por clientes do gênero masculino e feminino.

	gender text	total_receita numeric
1	Female	75191
2	Male	157890

2. Clientes com Alto Gasto utilizando Desconto

Identificação de clientes que utilizaram descontos, mas ainda assim gastaram acima do valor médio de compra.

	customer_id bigint	purchase_amount bigint
1	2	64
2	3	73
3	4	90
4	7	85
5	9	97
6	12	68
7	13	72
8	16	81
9	20	90
10	22	62
11	24	88
12	29	94
13	32	79
14	33	67
15	35	91

3. Top 5 Produtos por Avaliação

Identificação dos produtos com as maiores médias de avaliações dos clientes.

	item_purchased text	media_avaliacao numeric
1	Gloves	3.86
2	Sandals	3.84
3	Boots	3.82
4	Hat	3.80
5	Skirt	3.78

4. Comparação por Tipo de Envio

Comparação do valor médio das compras entre os tipos de envio *Standard* e *Express*.

	shipping_type text	media_compra numeric
1	Express	60.48
2	Standard	58.46

5. Assinantes vs. Não Assinantes

Comparação do gasto médio e da receita total entre clientes assinantes e não assinantes.

	subscription_status text	count bigint	media_compra numeric	receita_total numeric
1	No	2847	59.87	170436.00
2	Yes	1053	59.49	62645.00

6. Produtos Dependentes de Desconto

Identificação dos 5 produtos com a maior porcentagem de compras realizadas com desconto.

	item_purchased text	taxa_compra_desconto numeric
1	Hat	50.00
2	Sneakers	49.00
3	Coat	49.00
4	Sweater	48.00
5	Pants	47.00

7. Segmentação de Clientes

Classificação dos clientes em segmentos como **Novo**, **Recorrente** e **Fiel**, com base no histórico de compras.

	customer_segment text	numero_clientes bigint
1	Cliente_fiel	3116
2	Cliente_regular	701
3	Cliente_novo	83

8. Top 3 Produtos por Categoria

Listagem dos produtos mais comprados dentro de cada categoria.

	item_rank bigint	category text	item_purchased text	total_orders bigint
1	1	Accessori...	Jewelry	171
2	2	Accessori...	Sunglasses	161
3	3	Accessori...	Belt	161
4	1	Clothing	Blouse	171
5	2	Clothing	Pants	171
6	3	Clothing	Shirt	169
7	1	Footwear	Sandals	160
8	2	Footwear	Shoes	150
9	3	Footwear	Sneakers	145
10	1	Outerwear	Jacket	163
11	2	Outerwear	Coat	161

9. Compradores Frequentes e Assinaturas

Verificação se clientes com mais de 5 compras possuem maior probabilidade de assinar o serviço.

	subscription_status text	cliente_recorrente bigint
1	No	2518
2	Yes	958

10. Receita por Faixa Etária

Cálculo da contribuição total de receita gerada por cada faixa etária.

	age_group text	total_clientes bigint	total_receita numeric
1	Young adult	1028	62143
2	Middle-aged	986	59197
3	Adult	942	55978
4	Senior	944	55763

Dashboard no Power BI

Por fim, foi desenvolvido um dashboard interativo no Power BI para apresentar os insights de forma visual e intuitiva.



Conclusão

Com base nas análises realizadas, foi possível identificar oportunidades importantes para melhorar os resultados do negócio. Os dados mostram que clientes assinantes e consumidores recorrentes possuem maior potencial de gerar receita, reforçando a importância de investir em benefícios exclusivos para assinantes e programas de fidelidade para incentivar a retenção de clientes.

Além disso, os resultados indicam que os descontos influenciam diretamente as vendas, sendo necessário equilibrar estratégias promocionais com o controle das margens de lucro. Também foi possível identificar produtos com melhores avaliações e maior desempenho, permitindo destacá-los em campanhas de marketing e melhorar o posicionamento dos produtos.

Por fim, a análise dos perfis de clientes possibilita a criação de campanhas mais direcionadas, focando principalmente em faixas etárias e consumidores com maior geração de receita.